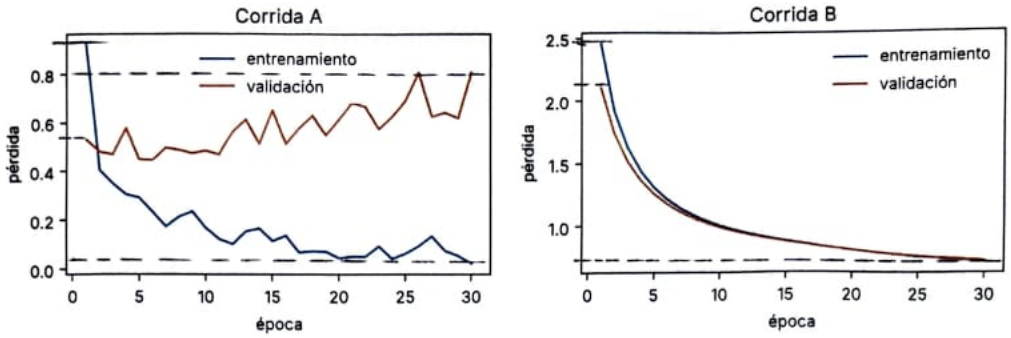
SI7011 · Evento evaluativo 1 · Parte A: leer la evidencia

Nombre: Israel Garnica / Andrés Felipe Agudelo Bohórquez Ortega **Documento:** 91080347 / 1037672497

Individual · sin computador ni apuntes · 30 minutos · 6 preguntas, 1 punto cada una.
Respuestas cortas: una o dos frases por literal. Cuando la pregunta pide evidencia, cita un número leído de la figura.

---

1. Dos corridas



a) Diagnostica cada corrida en una frase, citando lo que ves en las curvas.

En la corrida A, el entrenamiento converge en la época 30 disminuyendo la pérdida hasta 0,03, pero en validación, aumenta hasta 0,8. En A, aprende bien, pero generaliza mal. En la corrida B entrenamiento y validación son menos erráticas, convergiendo hasta 0,75. En B el comportamiento de validación es bueno, pero podría necesitar más épocas si se quiere reducir aun más la pérdida.

b) Propón **una** acción para cada corrida y di qué cambio en las curvas confirmaría que funcionó.

Corrida A: Si se utiliza early stopping, es posible detener el entrenamiento si la pérdida de validación muestra desmejoría; en este caso, en una época cercana a la 6 pararía, si no se observa mejora en 3 épocas de paciencia.

Corrida B: Aumentaría el número de épocas para disminuir el error.

2. Un cálculo de varianza

Una capa ReLU con $n_{\text{in}} = 400$ y pesos $W \sim \mathcal{N}(0, 0.05^2)$. Supón que ReLU conserva la mitad de la varianza.

a) ¿Por qué factor se multiplica $\text{Var}(a_l)$ en cada capa? → en cada capa, la varianza se multiplica x 0,5.

Para conservar 0,5 de varianza → $\frac{1}{2} n_{in} \sigma^2 = \frac{1}{2}(400) \times (0,05)^2 = 200 \cdot 0,0025 = 0,5$

b) Después de 10 capas, ¿cuánto vale $\text{std}(a_{10})$ en proporción a la inicial? → std(a_{10}) es 3,13% del inicial.

varianza relativa → $0,5^{10}$ → asumiendo que la 1era capa esta normalizdad → $\text{Std}(a_0) = 1$ → $\frac{\text{std}(a_{10})}{\text{Std}(a_0)} = \frac{\sqrt{0,5^{10}}}{\sqrt{1}} \approx 0,03125$

c) ¿Qué desviación estándar σ conserva la varianza? ¿Cómo se llama esa inicialización?

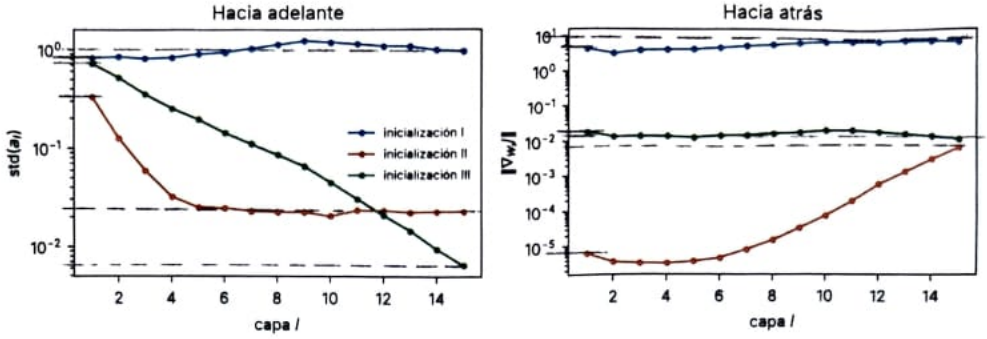
El método de inicialización que conserva la varianza es He, para redes que usan ReLU.

si $\frac{1}{2} n_{in} \sigma^2 = 1$ → $\sigma^2 = \frac{2}{n_{in}}$ → $\sigma = \sqrt{\frac{2}{n_{in}}} = \sqrt{\frac{2}{400}} = 0,0707$

se necesita una Std = 0,0707 para conservar σ^2 en 1

3. Tres inicializaciones

Un MLP de 15 capas ocultas con ReLU y 256 unidades, medido **antes de entrenar** sobre un lote, con tres inicializaciones: la de PyTorch por defecto, Xavier y He (en algún orden).



a) Asigna I, II y III a {PyTorch por defecto, Xavier, He}. Justifica cada una con un número de las gráficas.

I. Azul → (He) la desviación hacia adelante y atrás de std(a) y ∇ se mantiene muy cerca a la constante de 1 (10^0 y 10^1); presenta comportamiento óptimo en RELU

II. naranja → (PyTorch por defecto) los gradientes caen a 0,02 (10^{-5}) muy rápido. Esta inicialización produce una reducción pronunciada de STD y ∇, dificultando entrenamiento.

III. verde → (Xavier) Aunque los ∇ se mantienen constantes, las activaciones bajan la std a 0,02. La varianza disminuye ya que no compensa la reducción de RELU → STD baja y ∇ disminuye comparando con HE.

b) ¿Cuál entrenarías con SGD? ¿Qué les pasaría a las primeras capas con las otras dos?

Entrenaría con SGD (Stochastic Gradient Descent) con la inicialización I (He), porque mantiene activaciones y gradientes de magnitudes adecuadas.

Con las otras dos, los gradientes de las primeras capas serían muy pequeños, dificultando aprendizaje y produciendo desvanecimiento de gradientes; Podrían no salir de mínimo local o momentos de derivada 0; se requiere otro optimizador.

4. La pérdida inicial

Un problema con $C = 7$ clases balanceadas. Tres compañeros reportan la pérdida de **validación** **antes de entrenar** (entropía cruzada). Interpreta cada valor en una frase: ¿está bien? Si no, ¿qué sospechas?

entropía cruzada → $L = -\ln(p_y)$ → p_y es la probabilidad de asignación correcta de la clase

a) 1.95

si $L = -\ln\left(\frac{1}{7}\right) = \ln(7) \approx 1{,}946$ → esta bien, es una probabilidad esperada de predicción para cada una de las 7 clases.

b) 38.2 $\approx -\ln(10^{-16})$ → p muy pequeña

Respecto a la referencia, es muy alta. Seguramente habrá predicciones incorrectas, mala inicialización, o una función de pérdida errónea, o no estandarización de los datos; explotan las activaciones capa a capa.

c) 0.03

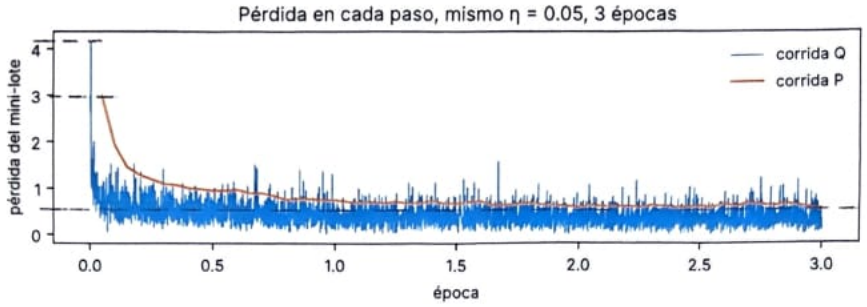
Respecto a la referencia, muy baja. Puede haber fuga de información, o error en la evaluación, o sobre entrenamiento., o batch muy pequeños o cercanos a 0.

→ $L = -\ln(p_y)$ → $p_y = e^{-L}$

$p_y = e^{-0{,}03} \approx 97$ de probabilidad de acierto, muy alta

5. Tamaño del lote

El mismo modelo con el mismo $\eta = 0.05$ durante 3 épocas. Una corrida usa lotes de 16 y la otra lotes de 1024. Corrida P: 0.14 s por época. Corrida Q: 0.82 s por época.



a) ¿Cuál corrida usa lotes de 16? Da dos razones que se vean en la figura o en los tiempos.

La corrida Q (azul) es la que usa los 16 lotes. Presenta más fluctuaciones en la pérdida y tarda más tiempo (0,82 s) por época. Los lotes o batch pequeños, producen estimaciones de gradiente más ruidosas, por que la cantidad de actualizaciones a la función de costo es mayor.

La corrida P (naranja) es más suave, sin tantas fluctuaciones, lo que puede indicar que el gradiente se calcula con más observaciones (1024 batch)

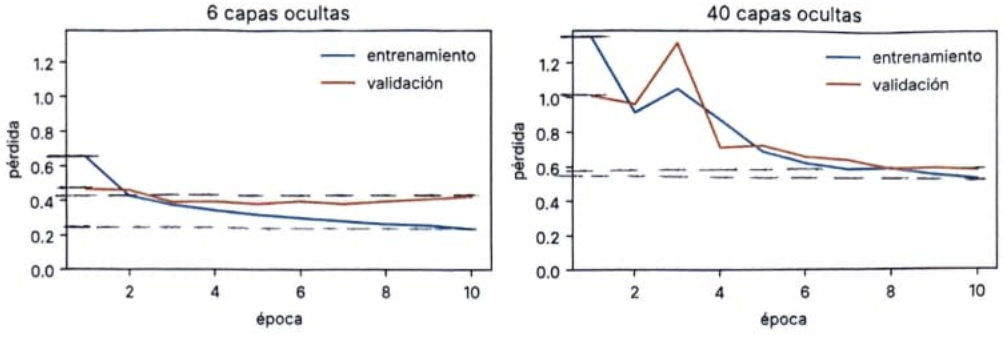
b) Si pasas de lotes de 16 a 1024 y quieres avanzar lo mismo por época, ¿qué haces con η? ¿Para qué sirve un *warmup*?

- Si pasamos de 16 → 1024 el batch, $\frac{1024}{16} = 64$, realizamos 64 veces menos actualizaciones por época.
- Una opción para avanzar lo mismo por época, será aumentar la tasa de aprendizaje η, de forma proporcional al tamaño del batch.

$$\eta_{nuevo} = 0{,}05 \cdot \frac{1024}{16} = 3{,}2.$$

- Este aumento debería ser gradual, no uniforme en todas las capas. El warmup permitería incrementarlo gradualmente al comienzo, evitando actualizaciones muy grandes, que desestabilicen el entrenamiento.

6. Profundidad y weight decay



a) Un estudiante dice: «la red de 40 capas sobreajusta; hay que agregarle Dropout». ¿Estás de acuerdo? Justifica con las curvas y propón qué cambiarías.

No estamos de acuerdo. La red de 40 capas, termina en la época 10 con valores de entrenamiento y validación cercanos a 0,5, relativamente alto y cercano. No coincide con patrones de sobreajuste, sino de optimización. Como es una red profunda, no agregaríamos Dropout. Se probarían conexiones residuales o un cambio en la inicialización para facilitar el entrenamiento, o normalizar e iniciar con He. En la red de 6 capas se puede generalizar a partir de la época 4. Se podría aplicar early stopping entre las épocas 3-4 para evitar sobreajuste.

b) `torch.optim.Adam(..., weight_decay=λ)` frente a `torch.optim.AdamW(..., weight_decay=λ)`: ¿qué hace cada uno con la penalización, y por qué se prefiere AdamW?

Ambos códigos usan el parámetro weight_decay, pero de forma diferente.

Adam: incorpora penalización L2 dentro del gradiente, para luego procesarlo por el optimizador adaptativo; regularización acoplada.

AdamW: aplica el decaimiento de los pesos por separado de la actualización adaptativa, es decir, desacopla el weight decay de la actualización del optimizador. AdamW se prefiere, porque permite regularizar los pesos de forma directa y controlada.

Porque se prefiere AdamW: Se prefiere AdamW porque separa la corrección del error de la reducción de los pesos. Así, controla mejor la penalización, evitando pesos excesivamente grandes y ayudando al modelo a realizar mejores predicciones con datos nuevos.