SI7011 · Evento evaluativo 3 · Parte A: leer la evidencia

Nombre: Israel Garnica Bohórquez / Andrés Felipe Agudelo Ortega **Documento:** 91080347 / 1037672497

Individual · sin computador ni apuntes · 45 minutos · 8 preguntas, 1 punto cada una.
Respuestas cortas: una o dos frases por literal. Cuando la pregunta pide evidencia, cita un número leído de la figura o la tabla. Todos los resultados son de corridas reales de los notebooks de las sesiones 05 y 06.

---

1. Partir una serie de tiempo

Jena Climate: ventanas de 120 horas, predecir la temperatura 24 horas después. La línea base dice «la temperatura en 24 h será la de ahora». El mismo MLP se entrena con dos particiones: **en el tiempo** (el primer 50 % entrena, el siguiente 25 % valida) o **barajada** (se barajan las ventanas del primer 75 % y se separan al azar). La prueba es siempre el último 25 % de la serie.

MAE (°C)	validación	prueba
línea base	2.44	2.62
MLP, partición en el tiempo	2.50	2.67
MLP, partición barajada	2.30	2.57

a) Con la partición barajada, la validación promete que el MLP mejora a la línea base en 0.14 °C. ¿Cuánto la mejora en prueba? ¿Y con la partición en el tiempo, qué habría dicho la validación? Usa números de la tabla.

Con la partición barajada, el MLP mejora apenas 0,05 °C en prueba (2,62 - 2,57) respecto a la diferencia de 0,14 °C en validación (2,44 - 2,3). Con la partición temporal, el MLP es 0,06 °C peor que la línea base (2,44 - 2,5).

b) ¿Por qué barajar las ventanas antes de partir produce una fuga, si ninguna ventana aparece dos veces?

Por el solapamiento. Por ejemplo, si la ventana 1 comprende las horas 1 a 120, y la ventana 2, las horas 2 a 121, estas comparten 119 horas. Esto hace que el error de validación parezca menor, siendo muy optimista.

c) La temperatura media del bloque de entrenamiento es 8.82 °C y la de toda la serie 9.44 °C. ¿Con cuál se normaliza, y por qué?

Se debe normalizar con la media de entrenamiento (8.82 °C), por que utilizar la media de toda la serie (9,44 °C) introduciría información del futuro, lo que produciría fuga de información.

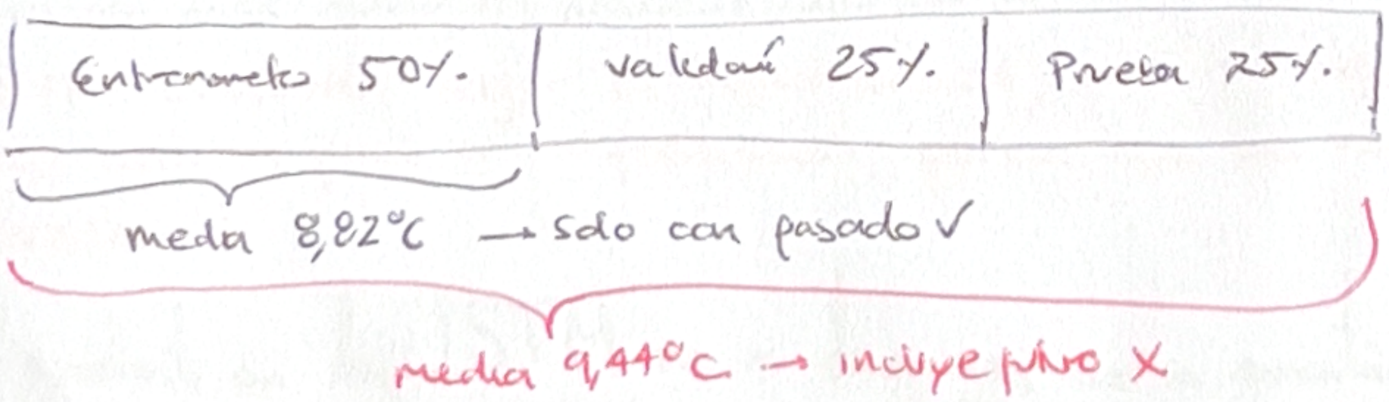

2. El gradiente a lo largo de la ventana

Tres modelos recurrentes entrenados en la misma tarea: una RNN simple, una LSTM y una GRU. La figura muestra cuánto cambia la pérdida con cada hora de la entrada.

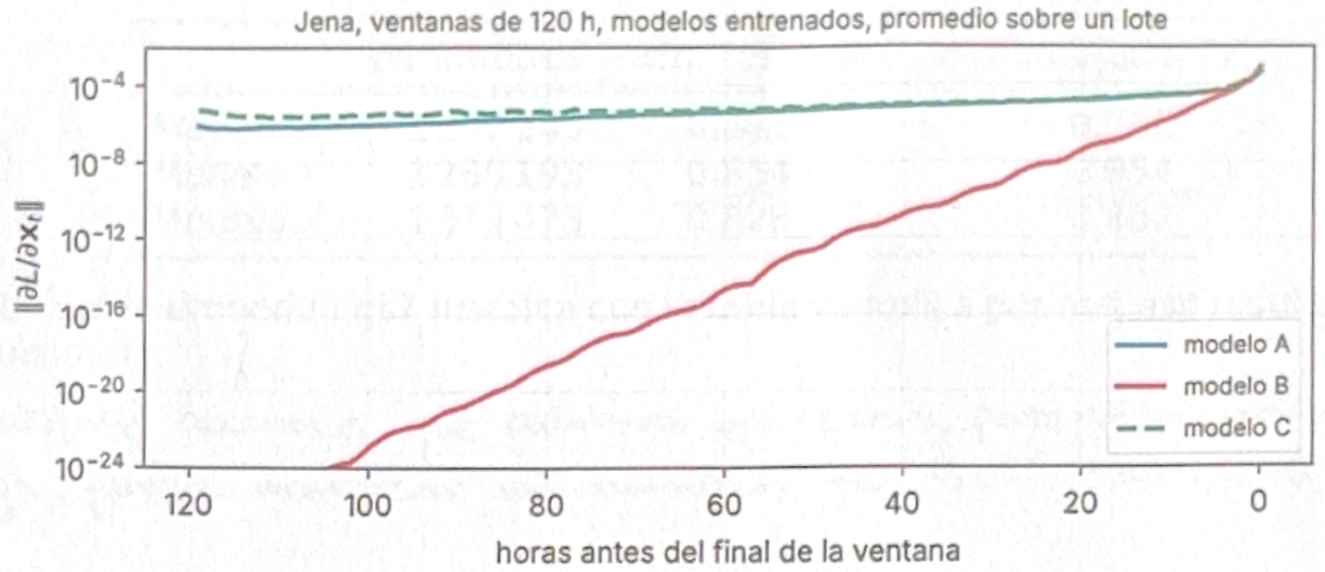

	parámetros	MAE validación (°C)
línea base	0	2.44
RNN, ventana de 120 h	529	2.33
RNN, ventana de 24 h	529	2.33
LSTM, ventana de 120 h	2 065	2.32
GRU, ventana de 120 h	1 553	2.30

a) ¿Cuál curva es la RNN simple? Justifica con un valor leído de la figura y explica de dónde sale esa forma.

La curva B (roja) es el RNN simple, porque su gradiente disminuye hasta 10^{-24} en ≈ 100 horas. Las multiplicaciones sucesivas en la retropropagación hacen que el gradiente se desvanezca, entre más antigua la información, la RNN aprende menos.

b) ¿Qué tiene la celda de la LSTM que evita esa forma?

La LSTM puede recordar información durante más tiempo porque dispone de un camino de memoria (compuertas) que facilita la propagación del gradiente.

c) La RNN da el mismo MAE con 120 h y con 24 h de ventana. ¿Qué dice eso, junto con la figura? Si la LSTM conserva el gradiente, ¿por qué casi no le gana a la RNN en esta tarea?

La RNN obtiene el mismo error (2,33°C) en 120 y 24 h, porque no logra aprovechar la información más antigua (desvanecimiento de ∇)

La LSTM conserva mejor la información, pero su mejora es pequeña. Los datos antiguos aportan poco a la predicción; parece que las horas más recientes, aportan más a la predicción.

Que el gradiente en la LSTM no se desvanezca no es garantía que los datos del pasado me den información para el futuro.

3. Barajar las palabras

IMDB, 20 000 reseñas de entrenamiento. Tres clasificadores: una **bolsa de embeddings** (promedio de los vectores de las palabras), una **CNN 1-D** y una **LSTM**. «Barajado» quiere decir que en el test se barajan las palabras de cada reseña, sin volver a entrenar.

	parámetros	acc. test	acc. test barajado
Modelo X	1 292 545	0.841	0.796
Modelo Y	1 280 193	0.854	0.854
Modelo Z	1 313 473	0.826	0.807

a) ¿Cuál es la bolsa de embeddings? Justifica con la tabla y explica por qué ese resultado es exacto, no una casualidad.

La bolsa de embeddings reconoce qué palabras aparecen, pero no su orden. El modelo Y es la bolsa de embeddings, porque mantiene un accuracy de 0,854 incluso al barajar.

b) ¿Qué dice este experimento sobre si clasificar el sentimiento de una reseña necesita un modelo que tenga en cuenta el orden?

Reconocer las palabras puede ser suficiente para identificar sentimientos, aunque el orden ayuda a interpretar algunas frases. Esto hace que el test sin barajar sea un poco mejor en metricas que barajado.

c) Con embeddings GloVe preentrenados **congelados**, la bolsa da 0.753; con GloVe **ajustados** a IMDB, 0.859. ¿Por qué la diferencia, si los dos parten de los mismos vectores?

GloVe aporta conocimientos previos sobre las palabras, pero el modelo congelado no los modifica. Con GloVe ajustado, el modelo adapta los vectores a las reseñas IMDB, mejorando accuracy.

4. El cuello de botella del seq2seq

Fechas en palabras a formato ISO: «el primero de mayo de 2 0 2 6» → `2026-05-01`. El encoder y el decoder son GRU de tamaño d. Exactitud por posición de la salida:

	parám.	exacta		año		-	mes		-	día	
sin atención, $d = 24$	14 204	0.004	1.00	1.00	0.98	0.95	1.00	0.76	**0.15**	1.00	**0.32**	**0.09**
sin atención, $d = 96$	99 020	1.000	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00
con atención, $d = 24$	16 220	1.000	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00

a) Sin atención, ¿qué recibe el decoder del encoder? Con eso, explica por qué $d = 24$ falla y $d = 96$ no.

Sin atención, el decoder recibe un único valor que resume toda la frase. Con d=24, el vector no conserva suficiente información (0,004); en cambio, d=96 tiene mayor capacidad (1,000)

b) Los errores se concentran en el día y el mes. Mira el orden de la frase de entrada: ¿por qué esos y no el año?

Los errores se concentran en día y mes porque aparecen tarde en la frase y pueden perderse durante el procesamiento. Año está al final, y se conserva en la memoria del encoder.

c) La atención agrega menos de 2 100 parámetros y resuelve la tarea con $d = 24$. ¿Qué cambia en lo que el decoder puede leer?

La atención permite al decoder consultar las diferentes partes de la frase, en lugar de depender de un único vector de memoria.

5. Máscaras y posiciones

La misma capa de autoatención sobre «me senté en el banco», rellenada con dos `[PAD]` para formar un lote. Cada mapa muestra los pesos de atención α_{ij} con una máscara distinta: ninguna, de relleno, o causal más relleno.

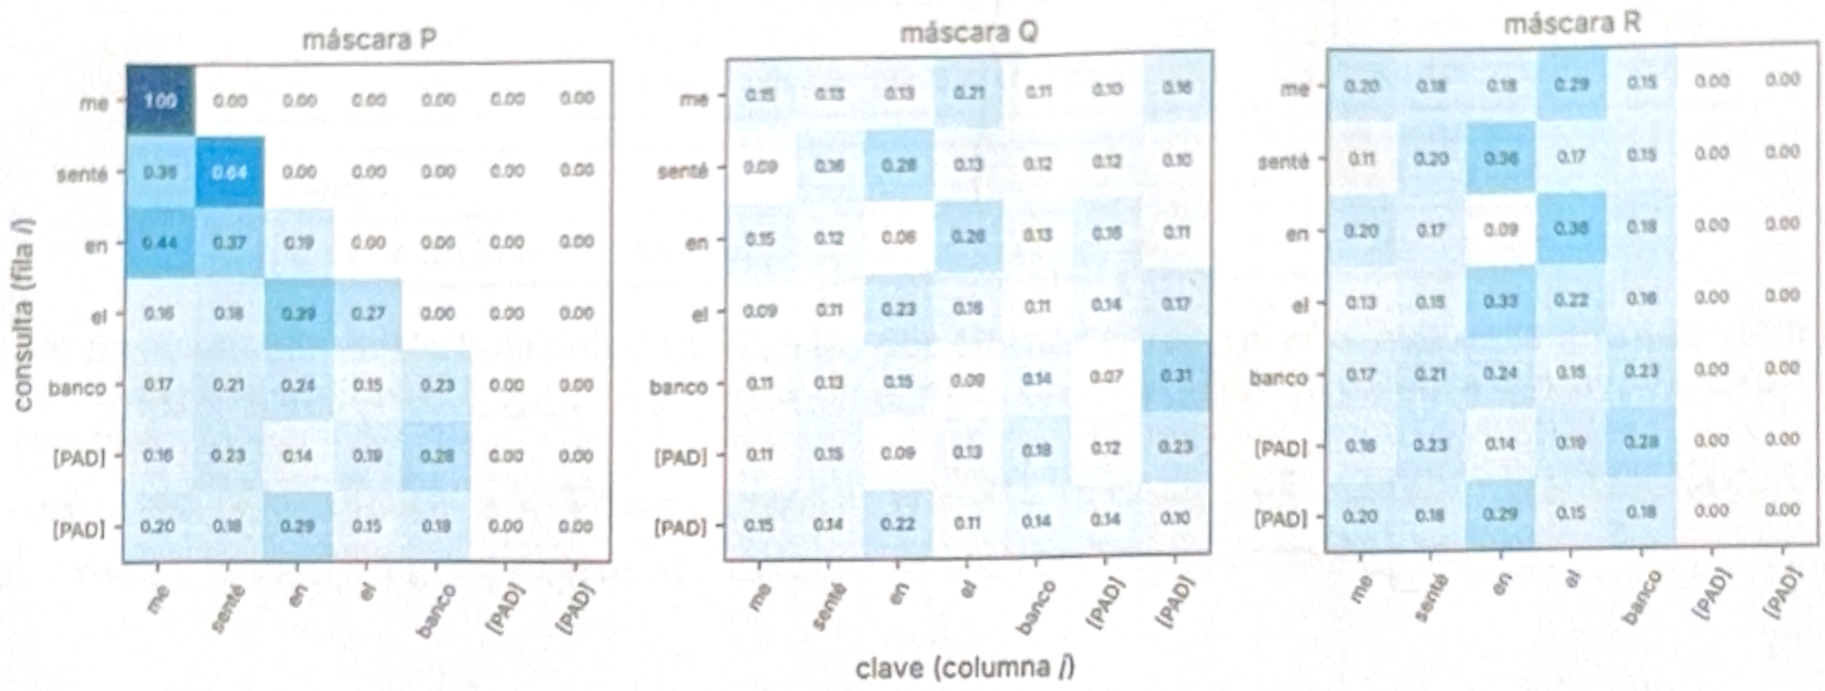

a) Asigna P, Q y R. Justifica cada una con lo que ves en el mapa.

(P) es causal + relleno → solo permite consultar palabras anteriores o la actual, el resto $\alpha_{ij} = 0$.

(Q) es ninguna → atiende todas las posiciones, incluidos los PADs.

(R) es relleno (padding) → consulta las 5 palabras, pero asigna atención = 0 a columnas PAD.

b) ¿Qué problema produce Q en un lote con frases de distinto largo?

Q no bloquea los PADs, espacios de relleno para igualar la longitud de las frases. El modelo prestaría atención a posiciones vacías, y no a palabras reales.

c) Sin embeddings de posición, se reordenan las cinco palabras y se pasan por la misma capa: las salidas son las mismas, en el nuevo orden (diferencia máxima $9 \cdot 10^{-8}$). Con posiciones, la diferencia es 0.23. ¿Por qué? ¿Qué consecuencia tiene para «el perro mordió al hombre» y «el hombre mordió al perro»?

Sin embedding de posición, el modelo no distingue el orden de las palabras. Con las posiciones, el Transformer sí puede distinguir quien hace la acción y quién la recibe

6. El Transformer de las fechas y su costo

La misma tarea de la pregunta 4 con un Transformer encoder-decoder, $d = 64$, 245 964 parámetros.

	exacta		año			-	mes		-	día	
con posición	0.999	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00
sin posición	0.660	0.99	0.99	**0.72**	**0.67**	1.00	1.00	1.00	1.00	0.95	0.90

longitud T	128	256	512	1 024	2 048
memoria de la matriz de atención (MB)	0.25	1	4	16	64

a) Sin posición, el modelo falla sobre todo en las dos últimas cifras del año, que en la entrada vienen como dígitos sueltos («2 0 2 6»), y nunca en el mes, que viene como palabra («mayo»). Explica por qué.

Sin embeddings de posición, el Transformer no distingue el orden de los dígitos del año, en cambio el mes "mayo" lo reconoce como una palabra completa.

b) ¿Por qué factor crece la memoria de la atención cuando T se duplica? ¿Cuánta ocuparía con $T = 4\,096$?

La memoria crece con los (tokens)^2, porque cada token se compara con todos los demás. Al duplicar T, la memoria se multiplica por 4, pasando a (64x4) = 256 MB para T= 4096.

c) ¿Cuántos parámetros tienen W_Q, W_K, W_V y W_O (con sesgo) de una capa de atención con $d = 64$? ¿Cambia ese número con T?

Las cuatro matrices tienen 16640 parámetros, incluyendo sesgos. Este número no depende de la cantidad de tokens, por que los mismos pesos se reutilizan para procesarlos; las matrices de pesos se mantienen; cambiaria la matriz de atención que depende de T^2.

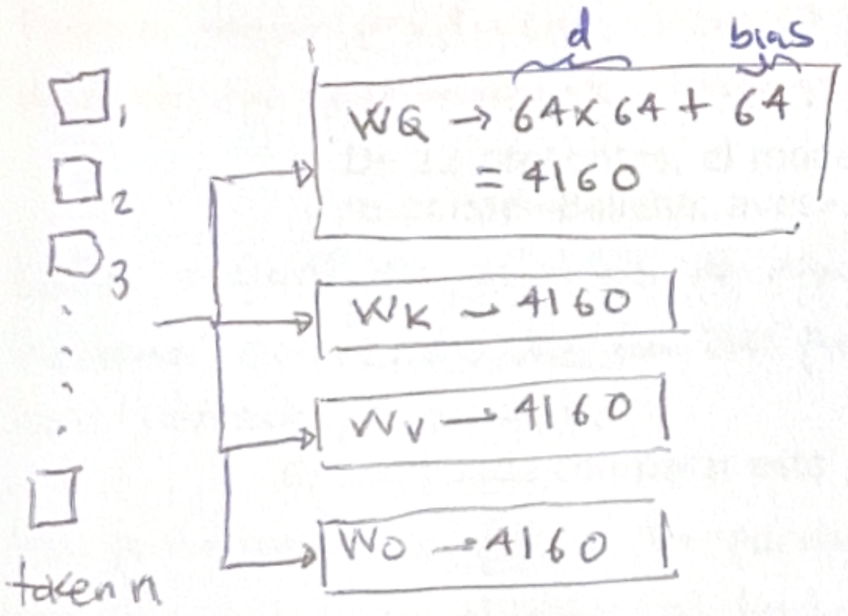

4 x 4160 parámetros
= 16,640 parámetros

7. La pérdida del ajuste supervisado

Un par pregunta–respuesta de Dolly en la plantilla de chat. Cada barra es la pérdida de predecir ese token con el modelo base, antes de ajustarlo.

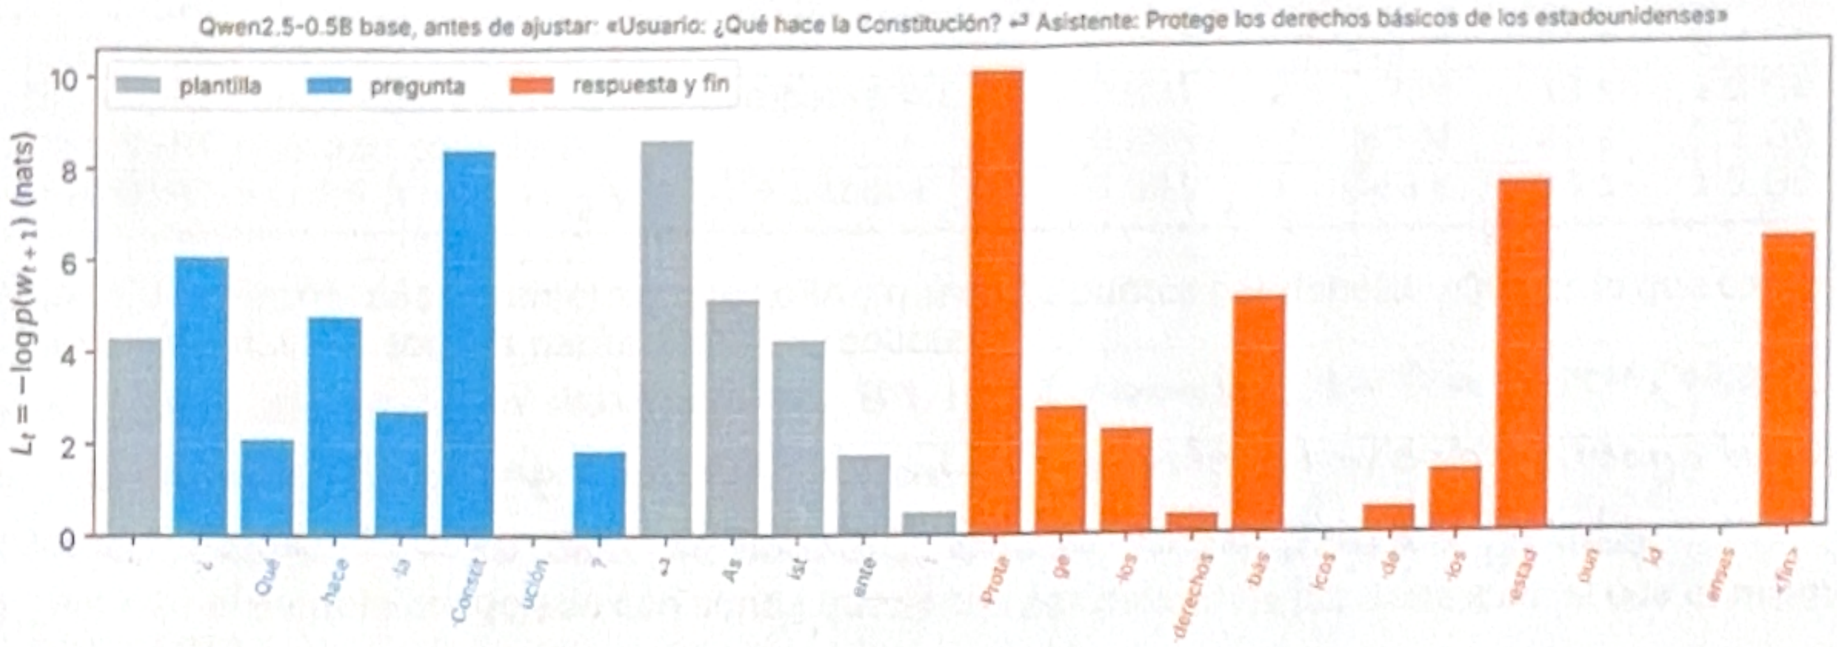

a) En el ajuste supervisado (SFT), ¿qué barras entran en la pérdida J y por qué las otras no? El promedio de las 26 barras es 3.36; el de las que cuentan, 2.82. ¿Cuál de los dos números optimiza el SFT?

En SFT se incluyen en J solo las barras de la rta del asistente y el token "fin". El objetivo es que el modelo aprenda a generar rtas, no predecir pregunta o plantilla. Por eso, la pérdida J optimizada es 2.82 nats/token.

b) Después de 250 pasos de LoRA, la J de validación pasa de 2.060 a 1.903 nats por token. Traduce los dos valores a perplejidad ($e^{2.06} \approx 7.8$, $e^{1.90} \approx 6.7$) y explica qué significa ese número.

La perplejidad mide qué tan difícil le resulta al modelo predecir el siguiente token. Si disminuye, indica mejor predicción. Después de 250 pasos de LoRA, PPL disminuye de 7,85 a 6,71, indicando mejoría en confianza de predicción.

c) De 12 preguntas, el modelo base se detiene solo en 2; después del ajuste, en 9. Pero ahora responde «Ballena: aves». ¿Qué aprendió el modelo en 250 pasos, y qué no?

LoRA mejoró en aciertos de rtas (de 2/12 a 9/12), pero todavía se equivoca, al clasificar la ballena erroneamente. En 250 pasos, el modelo aprendió cómo responder, pero no necesariamente que sea correcto, o exacto.

d) ¿Se puede comparar esta J con la de otro modelo que usa otro tokenizador? ¿Por qué?

No podríamos comparar la pérdida J por token entre modelos con diferentes tokenizadores, porque cada uno divide el texto en unidades distintas.

8. Elegir cómo usar un modelo preentrenado

IMDB con solo **2 000** reseñas de entrenamiento, 2 000 de test, GPU T4.

	acc. test	entrenables	tiempo	memoria
LSTM desde cero	0.778	4.2 M	15 s	0.7 GB
DistilBERT congelado + sonda logística sobre `[CLS]`	0.801	769	13 s	1.0 GB
DistilBERT ajustado completo	0.886	67 M	40 s	2.2 GB
DistilBERT + LoRA ($r = 8$, W_Q y W_V) + cabeza	0.891	740 k	34 s	1.5 GB

a) La LSTM entrena más parámetros que LoRA y queda 11 puntos por debajo. ¿Qué es lo que compra la exactitud, si no son los parámetros entrenables?

DistilBERT con LoRA alcanza un accuracy de 89,1%. superando 11,3 % a LSTM (77,8%). Esto pasa por aprovechar representaciones aprendidas durante pre-entrenamiento y luego adaptarlas, en lugar de aprender desde 0. Estas data de adaptación ajustan lo que el modelo ya sabe

b) ¿Por qué el modelo congelado con sonda queda tan por debajo de los ajustados, si usa el mismo DistilBERT?

DistilBERT congelado (accuracy 80,1%) solo entrena el clasificador final, sin modificar las representaciones de lenguaje. Los otros modelos se adaptan a la tarea de clasificación de sentimientos.

c) Una clínica tiene 800 notas clínicas en español etiquetadas para **tres** tareas distintas y una GPU de 16 GB. ¿Qué estrategia eliges y qué cambiarías del experimento de arriba? Nombra la línea base contra la que la compararías.

Usaríamos un modelo preentrenado en Español, biomédico, adaptado mediante LoRA, con clasificadores específicos para las 3 tareas. Así, aprovecharíamos el conocimiento específico previo, se reducen los parámetros entrenables y se adecuaría a los recursos de la clínica; para comparar su desempeño, se podría usar un modelo congelado, o con un modelo desde cero.