Anteproyecto - Estimación de posición 3D de un catéter con sensores Hall y Deep Learning

Asignatura: SI7011 — Aprendizaje Profundo - Universidad EAFIT

Profesor: Juan David Martínez Vargas

Estudiante: Israel Garnica Bohórquez **Asesor:** Chistian Diaz León – Universidad EAFIT

Programa: Doctorado en Ingeniería **Fecha:** 20 de octubre de 2026

---

1. Contexto y justificación

El entrenamiento en cirugía endovascular depende en gran medida de la fluoroscopia, lo que implica exposición repetida a radiación para residentes, especialistas y pacientes. Una alternativa es practicar en biomodelos físicos que registren la trayectoria del catéter en un ambiente controlado y sin radiación, lo que exige poder estimar la posición de la punta del catéter dentro del biomodelo.

En la asignatura previa (Aprendizaje de Máquina Aplicado) se desarrolló una prueba de concepto para estimar la posición 3D de un catéter magnetizado en un biomodelo vascular recto a partir de sensores Hall externos, usando datos sintéticos; el mejor modelo fue Random Forest (MAE_3D ≈ 2.7 mm). Posteriormente se migró a un montaje con sensores Hall 3D reales (MLX90393) y calibradores que entregan las coordenadas verdaderas, obteniendo por primera vez un dataset real etiquetado. Este anteproyecto propone aprovechar ese dataset para, mediante Deep Learning, reducir el error de predicción de la posición.

2. Problema y pregunta de investigación

Sobre el dataset real, el modelo actual se entrenó de forma exploratoria, sin una metodología sistemática de entrenamiento profundo: el mejor modelo individual es una MLP grande (MAE_3D 6.17 mm, R^2 0.92) y un híbrido RF+MLP baja el error 3D. El error no es homogéneo y se concentra en la dirección más difícil de estimar, lo que sugiere margen de mejora con una red diseñada y entrenada de forma principista.

Pregunta: ¿Puede una red neuronal profunda, entrenada con las técnicas del curso (inicialización, normalización, optimización y regularización), estimar la posición 3D del catéter con menor error que la línea base actual sobre el mismo dataset real?

3. Objetivo: Desarrollar y evaluar un modelo de Deep Learning que reduzca el error de estimación de la posición 3D del catéter sobre el dataset real de sensores Hall, respecto a la línea base actual.

4. Datos disponibles

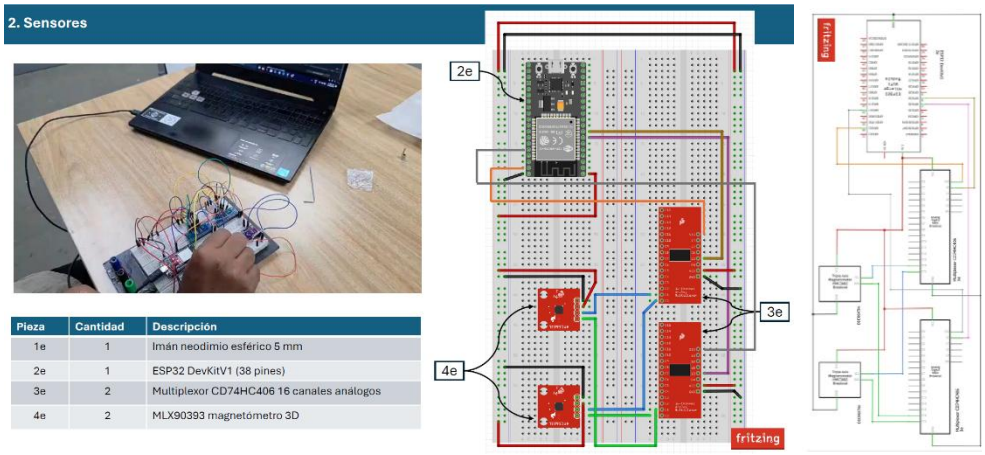
Dataset real obtenido con el montaje más reciente: 2352 muestras, 6 variables de entrada (dos magnetómetros MLX90393, tres ejes cada uno) y 3 variables objetivo (coordenadas x, y, z). Las coordenadas verdaderas provienen de calibradores impresos (49 posiciones × 3 repeticiones, cada 7.5 mm en z hasta 60 mm) y las lecturas se capturan con un ESP32. Se usará partición 80/20 train/test con semilla fija y estandarización ajustada solo en el conjunto de entrenamiento.

Obtención de los datos

Los datos se capturan en un montaje físico controlado:

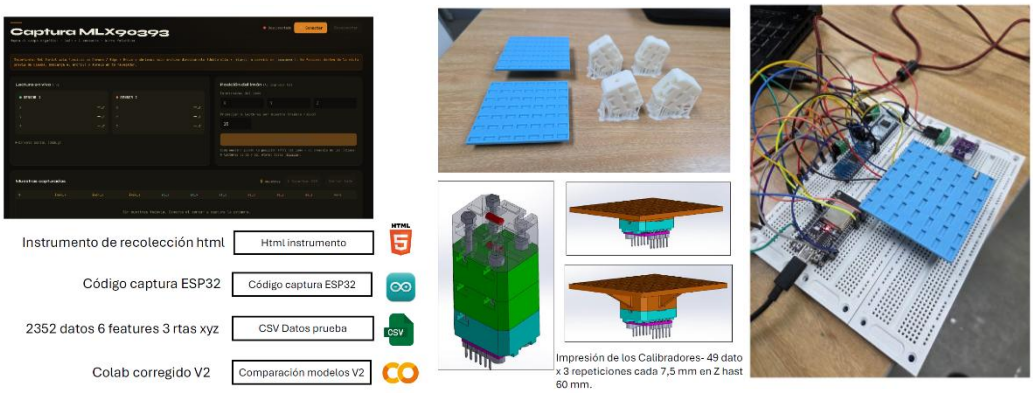
- La posición real (x, y, z) del imán se fija con calibradores impresos que lo ubican en coordenadas conocidas (49 posiciones, 3 repeticiones cada una, cada 7.5 mm en z hasta 60 mm), lo que da la etiqueta verdadera de cada muestra.
- Dos magnetómetros Hall 3D MLX90393, leídos mediante multiplexores y un microcontrolador ESP32, registran 6 valores (3 ejes × 2 sensores) por posición.
- Un instrumento de captura en HTML y el código del ESP32 guardan cada muestra (6 lecturas → etiqueta x, y, z) en un archivo CSV.

Figura 1. Hardware de sensado: ESP32 DevKitV1, dos multiplexores CD74HC406 y dos magnetómetros MLX90393, con el montaje en protoboard y su diagrama de conexión.



Pieza	Cantidad	Descripción
1e	1	Imán neodimio esférico 5 mm
2e	1	ESP32 DevKitV1 (38 pines)
3e	2	Multiplexor CD74HC406 16 canales análogos
4e	2	MLX90393 magnetómetro 3D

Figura 2. Instrumento de captura en HTML (Captura MLX90393) y calibradores impresos: 49 posiciones × 3 repeticiones, cada 7,5 mm en z hasta 60 mm. Cada muestra guarda las 6 lecturas y la posición real x, y, z. Los calibradores se van apilando para lograr las capas en z de lectura.



Acceso a los datos

Dataset etiquetado (CSV): dataLimpia (V2).csv

Código de captura (ESP32): Codigo_Captura_ESP32

Instrumento de recolección (HTML): captura_iman_mlx90393 (V2).html

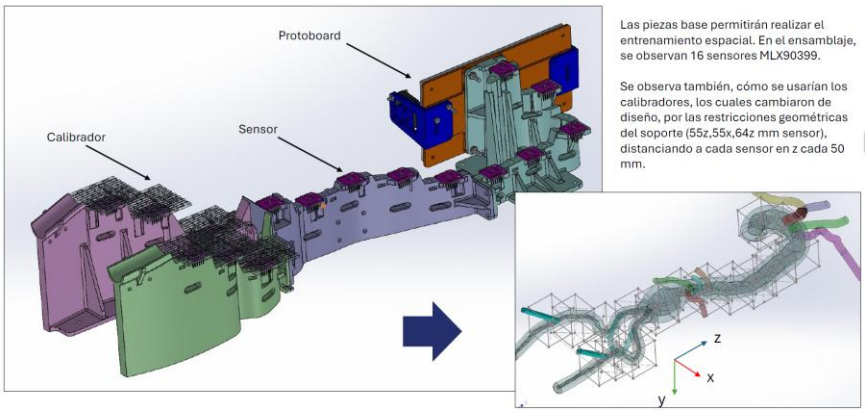
Entrenamiento (Colab): modelo_posicion_iman_MLX90393.ipynb

Alcance actual y expansión futura

El alcance de este proyecto se limita a explorar y comparar modelos de Deep Learning que, con la base de datos actual, mejoren la precisión en la predicción de las coordenadas del imán. Se espera que este modelo de DL pueda ser utilizado para el biomodelo completo.

La expansión a 16 sensores ubicados en la parte inferior del biomodelo de la aorta está en fase de desarrollo y queda fuera del alcance de este anteproyecto.

Figura 3. Fase futura (en desarrollo): disposición prevista de 16 sensores MLX90393 sobre los soportes de la aorta, separados cada 50 mm en z, con sus calibradores.



5. Metodología

El enfoque es una red profunda (MLP) bien entrenada, aplicando el toolkit de las sesiones S01–S02 del curso sobre un problema de regresión multi-salida (x, y, z):

- Inicialización adecuada (He/Xavier según la activación) para propagar bien la señal.
- Normalización (BatchNorm o LayerNorm) y activaciones ReLU o variantes.
- Optimización con Adam/AdamW y un schedule de tasa de aprendizaje.
- Regularización: weight decay, dropout y early stopping.
- Conexiones residuales para ganar profundidad sin degradación.
- Pérdida de regresión (MSE o Huber) sobre las tres coordenadas.

Cada decisión se toma frente a la evidencia del entrenamiento, no por defecto. La implementación será en PyTorch sobre Google Colab, en línea con las herramientas del curso.

A partir de la línea base se cambia un factor a la vez (inicialización, normalización, optimizador, regularización, profundidad/residuales), escribiendo la predicción antes de cada corrida y registrando el resultado. Métricas: MAE y RMSE 3D y por eje (x, y, z), R^2 y error máximo; se analiza la distribución del error en el volumen.

6. Resultados esperados y entregables

- Notebook ejecutado en PyTorch (datos → modelo → entrenamiento → evaluación), con las corridas visibles.
- Documento de análisis donde cada afirmación cita la corrida que la respalda.